LAB 0-4: Math for Machine Learning

Bài 1: Gradients và Hessians

Ma trận $\mathbf{A} \in \mathbb{R}^{m \times n}$ được gọi là đối xứng nếu $\mathbf{A}^T = \mathbf{A}$ hay $\mathbf{A}_{ij} = \mathbf{A}_{ji}$ với mọi i, j. Đồng thời, gradient $\nabla f(x)$ của hàm số $f : \mathbb{R}^n \to \mathbb{R}$ là vector n chiều của các đạo hàm riêng:

$$\nabla f(x) = \begin{bmatrix} \frac{\partial}{\partial x_1} f(x) \\ \vdots \\ \frac{\partial}{\partial x_n} f(x) \end{bmatrix} \quad \text{với} \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

Ma trận Hessian $\nabla^2 f(x)$ của hàm số $f : \mathbb{R}^n \to \mathbb{R}$ là ma trận đối xứng $n \times n$ gồm các đạo hàm riêng bậc hai:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2}{\partial x_1^2} f(x) & \frac{\partial^2}{\partial x_1 \partial x_2} f(x) & \cdots & \frac{\partial^2}{\partial x_1 \partial x_n} f(x) \\ \frac{\partial^2}{\partial x_2 \partial x_1} f(x) & \frac{\partial^2}{\partial x_2^2} f(x) & \cdots & \frac{\partial^2}{\partial x_2 \partial x_n} f(x) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2}{\partial x_n \partial x_1} f(x) & \frac{\partial^2}{\partial x_n \partial x_2} f(x) & \cdots & \frac{\partial^2}{\partial x_n^2} f(x) \end{bmatrix}$$

Tính gradient ($\nabla f(x)$) và ma trận Hessian ($\nabla^2 f(x)$) của các hàm số sau:

(a) $f(x) = a^T x$ với $a, x \in \mathbb{R}^n$.

$$f(x) = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} a_1 x_1 & a_2 x_2 & \cdots & a_n x_n \end{bmatrix}$$

$$\Rightarrow \nabla f(x) = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \end{bmatrix} = a^T$$

$$\Rightarrow \nabla^2 f(x) = 0$$

(b) $f(x) = x^T x$ với $x \in \mathbb{R}^n$.

$$f(x) = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} x_1^2 & x_2^2 & \cdots & x_n^2 \end{bmatrix}$$

$$\Rightarrow \nabla f(x) = \begin{bmatrix} 2x_1 & 2x_2 & \cdots & 2x_n \end{bmatrix}$$

$$\Rightarrow \nabla^2 f(x) = \begin{bmatrix} 2 & 0 & 0 \cdots & 0 \\ 0 & 2 & 0 \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 2 & 0 \cdots & 2 \end{bmatrix} = 2I$$

(c) $f(x) = x^T A x$ với $A \in \mathbb{R}^{n \times n}$ và $x \in \mathbb{R}^n$.

$$f(x) = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$f(x) = \sum_{i=1}^{n} \sum_{j=1}^{n} x_i a_{ij} x_j$$

$$\Rightarrow \frac{\partial}{\partial x_k} f(x) = \sum_{j=1}^{n} x_j a_{kj} + \sum_{i=1}^{n} x_i a_{ik} \quad \text{với} \quad k = 1 \to n$$

$$\Rightarrow \nabla f(x) = \begin{bmatrix} \sum_{j=1}^{n} x_j a_{1j} & \sum_{i=1}^{n} x_i a_{i1} \\ \sum_{j=1}^{n} x_j a_{2j} & \sum_{i=1}^{n} x_i a_{i2} \\ \vdots & \vdots \\ \sum_{j=1}^{n} x_j a_{nj} & \sum_{i=1}^{n} x_i a_{in} \end{bmatrix}$$

$$\Rightarrow \nabla f(x) = (A + A^T)x$$

$$\Rightarrow \nabla^2 f(x) = A + A^T$$

(d) $f(x) = \frac{1}{2} x^T A x + b^T x$, với A là ma trận đối xứng và $b \in \mathbb{R}^n$.

$$\text{A đối xứng} \Rightarrow A = A^T$$

$$f(x) = x^T A x + b^T x$$

$$\Rightarrow \nabla f(x) = Ax + b^T$$

$$\Rightarrow \nabla^2 f(x) = A$$

(e) $f(x) = g(h(x))$ với $g : \mathbb{R} \to \mathbb{R}$ và $h : \mathbb{R}^n \to \mathbb{R}$ khả vi.

$$\begin{aligned}
\frac{\partial}{\partial x_i} f(x) &= \frac{\partial g}{\partial h} \cdot \frac{\partial h}{\partial x_i} \\
\Rightarrow \nabla f(x) &= \frac{\partial g}{\partial h} \cdot \nabla h(x) \\
\Rightarrow \nabla^2 f(x) &= \frac{\partial^2 g}{\partial h^2} \cdot \nabla h(x) \nabla h(x) + \frac{\partial g}{\partial h} \cdot \nabla^2 h(x)
\end{aligned}$$

(f) $f(x) = g(a^T x)$ với $g : \mathbb{R} \to \mathbb{R}$ khả vi liên tục và $a \in \mathbb{R}^n$ là vector cố định.

$$\begin{aligned}
\nabla f(x) &= \frac{dg}{d(a^T x)} \cdot \nabla(a^T x) \\
\Rightarrow \nabla^2 f(x) &= \frac{d^2 g}{d(a^T x)^2} \cdot a \cdot \nabla(a^T x)
\end{aligned}$$

Bài 2: Ma trận xác định dương

Ma trận đối xứng $\mathbf{A} \in \mathbb{R}^{n\times n}$ được gọi là:

- Xác định dương ($\mathbf{A} \succ 0$): nếu $\mathbf{x}^T\mathbf{A}\mathbf{x} > 0$ ($\forall \mathbf{x} \neq \mathbf{0}$). Các trị riêng của $\mathbf{A} > 0$ và các định thức con chính dương.
- Nửa xác định dương ($\mathbf{A} \succeq 0$): nếu $\mathbf{x}^T\mathbf{A}\mathbf{x} \geq 0$ ($\forall \mathbf{x}$). Các trị riêng của $\mathbf{A} \geq 0$.
- Xác định âm ($\mathbf{A} \prec 0$): nếu $\mathbf{x}^T\mathbf{A}\mathbf{x} < 0$ ($\forall \mathbf{x} \neq 0$). Các trị riêng của $\mathbf{A} < 0$.
- Nửa xác định âm ($\mathbf{A} \preceq 0$): nếu $\mathbf{x}^T\mathbf{A}\mathbf{x} \leq 0$ ($\forall \mathbf{x}$). Các trị riêng của $A \leq 0$.
- Bất định ($\mathbf{A}$ indefinite): nếu tồn tại $\mathbf{x}, \mathbf{y}$ sao cho $\mathbf{x}^T\mathbf{A}\mathbf{x} > 0$ và $\mathbf{y}^T\mathbf{A}\mathbf{y} < 0$.

(a) Cho $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$. $\mathbf{A}$ là xác định dương, nửa xác định dương, xác định âm hay nửa xác định âm? Giải thích.

- Xac dinh

$$\begin{aligned}
\mathbf{x}^T\mathbf{A}\mathbf{x} &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \cdot \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
&= \begin{bmatrix} (2x_1 - x_2) & (-x_1 + 2x_2) \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
&= (2x_1 - x_2)x_1 + (-x_1 + 2x_2)x_2 \\
&= 2x_1^2 - x_1x_2 - x_1x_2 + 2x_2^2 \\
&= x_1^2 - 2x_1x_2 + x_2^2 + x_1^2 + x_2^2 \\
&= (x_1 - x_2)^2 + x_1^2 + x_2^2 \quad \geq 0 \quad (\forall x_1, x_2)
\end{aligned}$$

$\Rightarrow$Nửa xác định dương

- Tri rieng:

$$\begin{aligned}
&\det(\mathbf{A} - \lambda I) = 0 \\
&\Leftrightarrow \begin{vmatrix} 2-\lambda & -1 \\ -1 & 2-\lambda \end{vmatrix} = 0 \\
&\Leftrightarrow (2-\lambda)^2 - 1 = 0 \\
&\Leftrightarrow 4 - 4\lambda + \lambda^2 - 1 = 0 \\
&\Leftrightarrow \lambda^2 - 4\lambda + 3 = 0 \\
&\Rightarrow \lambda_1 = 1 \quad \lambda_2 = 3 \quad \Rightarrow \text{tri rieng} > 0 \\
&\det(\mathbf{A_1}) = 2, \quad \det(\mathbf{A_2}) = 3
\end{aligned}$$

$\Rightarrow$Xác định dương

(b) Cho $\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$. Xác định tính chất của $\mathbf{B}$.

- Tri rieng:

$$\begin{aligned}
&\det(\mathbf{A} - \lambda I) = 0 \\
&\Leftrightarrow \begin{vmatrix} 1-\lambda & 2 \\ 2 & 1-\lambda \end{vmatrix} = 0 \\
&\Leftrightarrow (1-\lambda)^2 - 4 = 0 \\
&\Leftrightarrow \lambda^2 - 2\lambda - 3 = 0 \\
&\Rightarrow \lambda_1 = -1 < 0 \qquad \lambda_2 = 3 > 0 \\
&\Rightarrow \text{Bất định}
\end{aligned}$$

(c) Chứng minh rằng nếu $\mathbf{A}$ là xác định dương thì $\mathbf{A}^{-1}$ cũng xác định dương.

$$\begin{aligned}
&\mathbf{A} \succ 0 \Rightarrow \mathbf{A} = \mathbf{A}^T,\ x^T\mathbf{A}x > 0\ \forall x \neq 0 \\
&\Rightarrow \mathbf{A} \text{ khả nghịch} \\
&\forall x \neq 0,\ \text{đặt } y = \mathbf{A}^{-1}x \neq 0 \\
&\Rightarrow x = \mathbf{A}y \\
&\Rightarrow x^T\mathbf{A}^{-1}x = (\mathbf{A}y)^T\mathbf{A}^{-1}(\mathbf{A}y) = y^T\mathbf{A}y > 0 \\
&\Rightarrow \mathbf{A}^{-1} \succ 0.
\end{aligned}$$

(d) Chứng minh rằng với mọi $\mathbf{X} \in \mathbb{R}^{m\times n}$, ma trận $\mathbf{X}^T\mathbf{X}$ luôn nửa xác định dương.

$$\begin{aligned}
&\mathbf{X}^T\mathbf{X} \Rightarrow (\mathbf{X}^T\mathbf{X})^T = \mathbf{X}^T\mathbf{X} \quad \text{(đối xứng)} \\
&\forall z \in \mathbb{R}^n,\ z^T\mathbf{X}^T\mathbf{X}z = (\mathbf{X}z)^T(\mathbf{X}z) = \|\mathbf{X}z\|^2 \geq 0 \\
&\Rightarrow \mathbf{X}^T\mathbf{X} \succeq 0.
\end{aligned}$$

(e) Cho hàm số $f(x) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} - b^T\mathbf{x}$ với $\mathbf{A}$ xác định dương. Chứng minh f là hàm lồi (convex) và tìm điểm cực tiểu.

$$\begin{aligned}
&\nabla f(x) = \mathbf{A}x - \mathbf{b} \\
&\nabla^2 f(x) = \mathbf{A} \\
&\mathbf{A} \succ 0 \Rightarrow \nabla^2 f(x) \succ 0 \Rightarrow f \text{ là hàm lồi} \\
&\nabla f(x) = 0 \Rightarrow \mathbf{A}x - \mathbf{b} = 0 \\
&\Rightarrow \mathbf{A}x = \mathbf{b} \Rightarrow x^* = \mathbf{A}^{-1}\mathbf{b}.
\end{aligned}$$

(f) Giải thích vai trò của ma trận xác định dương trong việc đảm bảo hàm mất mát có nghiệm tối ưu duy nhất.

Giả sử $f : \mathbb{R}^n \to \mathbb{R}$ khả vi hai lần và có Hessian $\nabla^2 f(x)$.

$$\nabla^2 f(x) \succeq 0 \Rightarrow f \text{ Hàm lồi}$$
$$\nabla^2 f(x) \succ 0 \Rightarrow f \text{ Hàm lồi nghiêm ngặt}$$

Nếu Hessian xác định dương thì:

- Có độ cong dương theo mọi hướng
- Mọi điểm dừng là cực tiểu toàn cục
- Nghiệm tối ưu là duy nhất
- $f(x) \to +\infty$ khi $\|x\| \to \infty$
- Thuật toán tối ưu hội tụ ổn định

Vì vậy, ma trận xác định dương bảo đảm bài toán tối ưu có cực tiểu toàn cục duy nhất và hành vi ổn định.

Bài 3: Trị riêng và vector riêng

Cho ma trận vuông $\mathbf{A} \in \mathbb{R}^{n\times n}$, giá trị riêng λ và vector riêng $\mathbf{v} \neq 0$ thỏa mãn:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Ma trận đối xứng $\mathbf{A}$ có thể được phân tích thành: $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$, trong đó $\mathbf{P}$ là ma trận trực giao chứa các vector riêng và $\mathbf{D}$ là ma trận đường chéo chứa các trị riêng tương ứng. Cho ma trận $\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix}$:

(a) Tìm các trị riêng của $\mathbf{A}$ bằng cách giải $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$.

$$\begin{aligned}
\det(\mathbf{A} - \lambda\mathbf{I}) &= \begin{vmatrix} 4-\lambda & 2 \\ 1 & 3-\lambda \end{vmatrix} \\
\Leftrightarrow &(4-\lambda)(3-\lambda) - 2 = 0 \\
\Leftrightarrow &\lambda^2 - 7\lambda + 10 = 0 \\
\Rightarrow &\lambda_1 = 5, \quad \lambda_2 = 2
\end{aligned}$$

(b) Tìm các vector riêng tương ứng với mỗi trị riêng.

- Với $\lambda_1 = 5$:

$$\mathbf{A} - 5I = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix}.$$

Giải hệ:

$$-x + 2y = 0 \Rightarrow x = 2y.$$

$$\Rightarrow v_1 = t \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

- Với $\lambda_2 = 2$:

$$\mathbf{A} - 2I = \begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix}.$$

Giải hệ:

$$2x + 2y = 0 \Rightarrow x = -y.$$

$$\Rightarrow v_2 = t \cdot \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

(c) Thực hiện phân tích eigen: $\mathbf{A} = \mathbf{PDP}^{-1}$.

$$\lambda_1 = 5, \quad \lambda_2 = 2.$$

$$v_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad v_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$\Rightarrow \mathbf{P} = \begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix}, \qquad \mathbf{D} = \begin{bmatrix} 5 & 0 \\ 0 & 2 \end{bmatrix}.$$

$$\det(\mathbf{P}) = 2 \cdot 1 - (-1) \cdot 1 = 3.$$

$$\Rightarrow \mathbf{P}^{-1} = \frac{1}{3} \begin{bmatrix} 1 & 1 \\ -1 & 2 \end{bmatrix}.$$

$$\Rightarrow \mathbf{A} = \mathbf{PDP}^{-1}$$

(d) Sử dụng phân tích eigen để tính $\mathbf{A}^5$.

$$\mathbf{A}^5 = (\mathbf{PDP}^{-1})^5 = \mathbf{PD}^5\mathbf{P}^{-1}$$

$$\mathbf{D}^5 = \begin{bmatrix} 5 & 0 \\ 0 & 2 \end{bmatrix}^5 = \begin{bmatrix} 5^5 & 0 \\ 0 & 2^5 \end{bmatrix} = \begin{bmatrix} 3125 & 0 \\ 0 & 32 \end{bmatrix}$$

$$\Rightarrow \mathbf{A}^5 = \begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3125 & 0 \\ 0 & 32 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & 1 \\ -1 & 2 \end{bmatrix}$$

$$= \begin{bmatrix} 2094 & 2062 \\ 1031 & 1052 \end{bmatrix}$$

(e) Ma trận $\mathbf{A}$ có xác định dương không? Giải thích.

$\mathbf{A}$ không đối xứng $\Rightarrow$ $\mathbf{A}$ khong

Bài 4: Xác suất và Biến đổi dữ liệu

Cho biến ngẫu nhiên X với hàm mật độ xác suất $p(x)$, kỳ vọng và phương sai được định nghĩa:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot p(x)\, dx$$
$$\mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}[X])^2\big] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Với vector ngẫu nhiên $\mathbf{X} \in \mathbb{R}^n$, ma trận hiệp phương sai được định nghĩa:

$$\mathrm{Cov}(\mathbf{X}) = \mathbb{E}\big[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^T\big]$$

Các công thức biến đổi quan trọng cần nhớ:

- $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$, và $\mathrm{Var}(aX + b) = a^2\mathrm{Var}(X)$.
- $\mathbb{E}[\mathbf{AX} + \mathbf{b}] = \mathbf{A}\mathbb{E}[\mathbf{X}] + \mathbf{b}$.
- $\mathrm{Cov}(\mathbf{AX}) = \mathbf{A}\,\mathrm{Cov}(\mathbf{X})\,\mathbf{A}^T$.

Thực hiện các bài toán sau

(a) Giả sử một biến ngẫu nhiên X (ví dụ: điểm thi) có kỳ vọng $\mu = 100$ và độ lệch chuẩn $\sigma = 20$. Biến đổi Z-score được định nghĩa:

$$Z = \frac{X - \mu}{\sigma} = \underbrace{\frac{1}{\sigma}}_{a} X - \underbrace{\frac{\mu}{\sigma}}_{b}$$

Sử dụng các tính chất của kỳ vọng và phương sai đã nêu ở đầu bài:

- Tính $\mathbb{E}[Z]$.

$$\begin{aligned}\mathbb{E}[Z] &= \mathbb{E}\left[\frac{1}{\sigma}X - \frac{\mu}{\sigma}\right] = \mathbb{E}\left[\frac{1}{20}X - \frac{100}{20}\right] = \frac{1}{20}\mathbb{E}[X] - 50 \\ &= \frac{1}{20}100 - 50 = 0\end{aligned}$$

- Tính $\mathrm{Var}(Z)$. (Lưu ý: $\mathrm{Var}(X) = \sigma^2$).

$$\mathrm{Var}(Z) = \mathrm{Var}\left(\frac{1}{\sigma}X - \frac{\mu}{\sigma}\right) = \frac{1}{\sigma^2}\mathrm{Var}(X) = 1$$

- Kết quả $\mathbb{E}[Z]$ và $\text{Var}(Z)$ cho thấy dữ liệu sau khi chuẩn hóa sẽ có phân phối tập trung quanh đâu và độ phân tán như thế nào?

  Ta có:

  $$\mathbb{E}[Z] = 0, \qquad \text{Var}(Z) = 1.$$

  Điều này cho thấy sau khi chuẩn hóa:

  - Dữ liệu tập trung quanh 0 (vì kỳ vọng bằng 0)
  - Độ phân tán bằng 1 (vì phương sai bằng 1).

  Do đó, dữ liệu sau chuẩn hóa có trung bình bằng 0 và độ lệch chuẩn bằng 1.

(b) Cho vector ngẫu nhiên $\mathbf{Z} \in \mathbb{R}^2$ tuân theo phân phối chuẩn tắc với: $\mathbb{E}[\mathbf{Z}] = \mathbf{0}$, và $\text{Cov}(\mathbf{Z}) = \mathbf{I}$. Ta tạo ra vector dữ liệu mới $\mathbf{X}$ bằng phép biến đổi tuyến tính:

$$\mathbf{X} = \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}, \quad \text{với } \mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}.$$

Hãy tính kỳ vọng $\mathbb{E}[\mathbf{X}]$ và ma trận hiệp phương sai $\text{Cov}(\mathbf{X})$.

- $\mathbb{E}[\mathbf{X}]$

$$\begin{aligned} \mathbb{E}[\mathbf{X}] &= \mathbb{E}[\mathbf{A}\mathbf{Z} + \boldsymbol{\mu}] = \mathbf{A}\mathbb{E}[\mathbf{Z}] + \boldsymbol{\mu} \\ &= \mathbf{A} \cdot 0 + \boldsymbol{\mu} = \boldsymbol{\mu} \\ \Rightarrow \mathbb{E}[\mathbf{X}] &= \begin{bmatrix} 5 \\ 1 \end{bmatrix} \end{aligned}$$

- $\text{Cov}(\mathbf{Z})$

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \text{Cov}(\mathbf{A}\mathbf{Z} + \boldsymbol{\mu}) = \mathbf{A}\text{Cov}(\mathbf{Z})\mathbf{A}^{\mathbf{T}} \\ &= \mathbf{A}\mathbf{I}\mathbf{A}^{\mathbf{T}} = \mathbf{A}\mathbf{A}^{\mathbf{T}} \\ \Rightarrow \text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 9 & 0 \\ 0 & 4 \end{bmatrix} \end{aligned}$$

(c) Cho hai biến ngẫu nhiên X_1, X_2 có ma trận hiệp phương sai:

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}.$$

Tính hệ số tương quan (correlation coefficient) giữa X_1 và X_2. Hai biến này có độc lập hay phụ thuộc? Nếu ta thay phần tử ngoài đường chéo bằng 3 (tức $\Sigma_{12} = \Sigma_{21} = 3$), mối quan hệ giữa chúng thay đổi thế nào?

- Ta có:

$$\begin{aligned} \mathrm{Var}(X_1) = 4 \quad &\Rightarrow \quad \sigma_1 = 2 \\ \mathrm{Var}(X_2) = 9 \quad &\Rightarrow \quad \sigma_2 = 3 \\ \mathrm{Cov}(X_1, X_2) = \mathrm{Cov}(X_2, X_1) &= 0 \end{aligned}$$

- Hệ số tương quan:

$$\rho = \frac{\mathrm{Cov}(X_1, X_2)}{\sigma_1 \sigma_2} = \frac{0}{2 \cdot 3} = 0$$

$\Rightarrow$ Hệ số tương quan bằng 0, hai biến không có tương quan tuyến tính.

- Thay phần tử ngoài đường chéo bằng 3:

$$\Sigma = \begin{pmatrix} 4 & 3 \\ 3 & 9 \end{pmatrix}$$

$$\mathrm{Cov}(X_1, X_2) = \mathrm{Cov}(X_2, X_1) = 3$$

$$\rho = \frac{\mathrm{Cov}(X_1, X_2)}{\sigma_1 \sigma_2} = \frac{3}{2 \cdot 3} = \frac{3}{6} = 0.5$$

$\Rightarrow$ Hai biến có tương quan dương mức trung bình ($\rho = 0.5$).

Điều này cho thấy khi X_1 tăng thì X_2 có xu hướng tăng theo. Chúng không còn độc lập nữa (kể cả trong trường hợp phân phối chuẩn).

Bài 5: Ước lượng hợp lý cực đại

Cho n mẫu quan sát độc lập $x_1, x_2, \ldots, x_n$ từ phân phối với tham số θ. Hàm likelihood được định nghĩa:

$$L(\theta) = \prod_{i=1}^{n} p(x_i \mid \theta)$$

Để thuận tiện cho việc tính toán, ta thường sử dụng log-likelihood:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log p(x_i \mid \theta)$$

Ước lượng MLE là giá trị $\hat{\theta}$ tối đa hóa log-likelihood:

$$\hat{\theta}_{\text{MLE}} = \arg\max_{\theta} \ell(\theta)$$

Tìm ước lượng MLE cho các phân phối sau:

(a) Phân phối Bernoulli: $P(X = 1) = p, P(X = 0) = 1 - p$. Tìm $\hat{p}_{\text{MLE}}$ từ n mẫu.

- Hàm likelihood:

$$\begin{aligned} L(p) &= \prod_{i=1}^{n} P(X = x_i) \\ &= \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} \\ &= \left(\prod_{i=1}^{n} p^{x_i}\right)\left(\prod_{i=1}^{n}(1-p)^{1-x_i}\right) \\ &= p^{\sum_{i=1}^{n} x_i}(1-p)^{\sum_{i=1}^{n}(1-x_i)} \\ &= p^{\sum_{i=1}^{n} x_i}(1-p)^{n-\sum_{i=1}^{n} x_i} \end{aligned}$$

- Ham log-likelihood:

$$\begin{aligned} \ell(p) &= \log L(p) \\ &= \left(\sum_{i=1}^{n} x_i\right)\log p + \left(n - \sum_{i=1}^{n} x_i\right)\log(1-p) \end{aligned}$$

- Lấy đạo hàm theo p:

$$\frac{d\ell(p)}{dp} = \frac{\sum_{i=1}^{n} x_i}{p} - \frac{n - \sum_{i=1}^{n} x_i}{1-p}$$

- Cho đạo hàm bằng 0:

$$\frac{\sum_{i=1}^{n} x_i}{p} = \frac{n - \sum_{i=1}^{n} x_i}{1-p}$$
$$\hat{p}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$\Rightarrow$ Ước lượng hợp lý cực đại của p là:

$$\boxed{\hat{p}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i}$$

(b) Phân phối chuẩn $\mathcal{N}(\mu, \sigma^2)$. Tìm $\hat{\mu}_{\text{MLE}}$ và $\hat{\sigma}^2_{\text{MLE}}$ từ n mẫu.

- Hàm likelihood:

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^{n} p(x_i|\mu, \sigma^2) \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) \end{aligned}$$

- log-likelihood:

$$\begin{aligned} \ell(\mu, \sigma^2) &= \log L(\mu, \sigma^2) \\ &= -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \end{aligned}$$

- $\hat{\mu}_{MLE}$

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu) = 0$$
$$\sum_{i=1}^{n}(x_i-\mu) = 0$$
$$\hat{\mu}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- $\hat{\sigma}^2_{MLE}$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{n}(x_i - \mu)^2 = 0$$
$$\hat{\sigma}^2_{MLE} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{\mu})^2$$

$\Rightarrow$ Vậy:

$$\boxed{\hat{\mu}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i}$$

$$\boxed{\hat{\sigma}^2_{MLE} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{\mu})^2}$$

(c) Phân phối Poisson

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Tìm $\hat{\lambda}_{\text{MLE}}$ từ n mẫu.

- Hàm likelihood:

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \\ &= \left(\prod_{i=1}^{n} \frac{1}{x_i!}\right) \lambda^{\sum x_i} e^{-n\lambda} \end{aligned}$$

- log-likelihood:

$$\begin{aligned} \ell(\lambda) &= \log L(\lambda) \\ &= \sum_{i=1}^{n} x_i \log \lambda - n\lambda - \sum_{i=1}^{n} \log(x_i!) \end{aligned}$$

- $\hat{\lambda}_{MLE}$:

$$\frac{d\ell}{d\lambda} = \frac{\sum x_i}{\lambda} - n = 0$$
$$\hat{\lambda}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$\Rightarrow \boxed{\hat{\lambda}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i}$$

(d) Phân phối mũ (Exponential):

$$p(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Tìm $\hat{\lambda}_{MLE}$ từ n mẫu.

- Hàm likelihood:

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^{n} \lambda e^{-\lambda x_i} \\ &= \lambda^n e^{-\lambda \sum x_i} \end{aligned}$$

- log-likelihood:

$$\ell(\lambda) = n \log \lambda - \lambda \sum x_i$$

- $\hat{\lambda}_{MLE}$:

$$\begin{aligned} \frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum x_i = 0 \\ \hat{\lambda}_{MLE} &= \frac{n}{\sum_{i=1}^{n} x_i} \end{aligned}$$

$$\Rightarrow \boxed{\hat{\lambda}_{MLE} = \frac{n}{\sum_{i=1}^{n} x_i}}$$

(e) Giải thích tối ưu log-likelihood

Vì hàm $\log(x)$ là hàm đơn điệu tăng nên:

$$\arg\max_{\theta} L(\theta) = \arg\max_{\theta} \log L(\theta)$$

Do đó tối ưu likelihood tương đương tối ưu log-likelihood.

Ưu điểm của log-likelihood:

- Chuyển tích thành tổng:

$$\log \left(\prod_{i=1}^{n} p(x_i|\theta) \right) = \sum_{i=1}^{n} \log p(x_i|\theta)$$

- Tính đạo hàm dễ hơn.
- Tránh hiện tượng underflow khi nhân nhiều xác suất nhỏ.
- Thuận tiện cho tối ưu hóa số học.